

Επεξήγηση Μοντέλων — MURA X-Ray Classification

Συγγραφέας: Γεώργιος Κιτσάκης **Μάθημα:** Deep Learning — AUEB

Γενική Εικόνα

Το πρόβλημα που λύνουμε είναι **δυναδική ταξινόμηση (binary classification)**: Δίνεται μια ακτινογραφία και το μοντέλο πρέπει να αποφανθεί αν είναι **φυσιολογική (normal)** ή **παθολογική (abnormal)**.

Το dataset **MURA** (Stanford) περιέχει ~40.000 ακτινογραφίες 7 σωματικών περιοχών (ώμος, αγκώνας, καρπός, χέρι, δάχτυλο, πήχης, βραχίονας).

Μοντέλο 3 — EfficientNetB0 (Μεταφορά Γνώσης)

Τι είναι το EfficientNetB0;

Το EfficientNetB0 είναι ένα **προεκπαιδευμένο νευρωνικό δίκτυο** — έχει ήδη μάθει να αναγνωρίζει χαρακτηριστικά σε εικόνες από το ImageNet (1.2 εκατομμύρια φωτογραφίες). Δεν έχει δει ποτέ ακτινογραφία, αλλά ξέρει ήδη τι είναι ακμές, υφές, σχήματα.

Τι το κάνει ξεχωριστό; Τα παραδοσιακά δίκτυα γίνονται καλύτερα είτε πηγαίνοντας **πιο βαθιά** (περισσότερα layers) είτε **πιο φαρδιά** (περισσότερα φίλτρα). Το EfficientNet χρησιμοποιεί **compound scaling** — κλιμακώνει ταυτόχρονα βάθος, πλάτος ΚΑΙ ανάλυση εικόνας σε βέλτιστη αναλογία. Αποτέλεσμα: καλύτερη απόδοση με λιγότερες παραμέτρους.

Αρχιτεκτονική

```
EfficientNetB0 (ImageNet weights, χωρίς top) → 1280-διάστατο διάνυσμα  
Dense(256, ReLU, L2 regularization)  
Dropout(0.5)  
Dense(1, Sigmoid) → πιθανότητα "abnormal"
```

Εκπαίδευση σε 2 Φάσεις

Φάση 1 — Frozen backbone (10 epochs, lr=0.001): Παγώνουμε όλα τα 239 layers του EfficientNetB0. Μόνο το νέο "κεφάλι" (Dense layers) εκπαιδεύεται. Γιατί; Γιατί αν αφήσουμε τα τυχαία βάρη του κεφαλιού να επηρεάσουν το backbone αμέσως, θα καταστρέψουν τα ImageNet χαρακτηριστικά πριν μάθει κάτι χρήσιμο.

Φάση 2 — Partial unfreeze + Cosine LR decay (έως 30 epochs): Ξεπαγώνουμε μόνο τα **τελευταία 30 layers**. Τα πρώτα layers (ακμές, υφές) είναι ήδη τέλεια για οποιαδήποτε εικόνα — δεν χρειάζεται να τα αλλάξουμε. Μόνο τα βαθύτερα layers που εντοπίζουν high-level χαρακτηριστικά χρειάζονται προσαρμογή για ακτινογραφίες.

Αντί για ReduceLROnPlateau, χρησιμοποιούμε **Cosine Decay**: το learning rate μειώνεται ομαλά ακολουθώντας καμπύλη cosinus από 3e-5 μέχρι σχεδόν μηδέν. Πιο ομαλή σύγκλιση, λιγότερη πιθανότητα να "κολλήσει".

Αποτελέσματα

Μέτρο	Τιμή
Val Accuracy	73.98%
Val Loss	0.6138
Recall (Abnormal)	60.1%

Μοντέλο 4 — Dual-Backbone Fusion (MobileNetV2 + EfficientNetB0)

Η Ιδέα


Αντί για ένα backbone, χρησιμοποιούμε **δύο παράλληλα**. Κάθε backbone "βλέπει" την ίδια εικόνα αλλά εξάγει **διαφορετικά χαρακτηριστικά**. Ενώνουμε τα δύο διανύσματα χαρακτηριστικών και αφήνουμε τον classifier να αποφασίσει βασισμένος και στα δύο.

Γιατί δύο backbones; Το MobileNetV2 και το EfficientNetB0 έχουν εκπαιδευτεί με διαφορετικές αρχιτεκτονικές:

- **MobileNetV2:** Χρησιμοποιεί *inverted residual blocks* — σχεδιασμένο για αποδοτικότητα, μαθαίνει compact αναπαραστάσεις
- **EfficientNetB0:** Χρησιμοποιεί *compound scaling* — πιο βαθύ, πιο φαρδύ, εκπαιδευμένο σε υψηλότερη ανάλυση

Αυτό που "χάνει" το ένα, μπορεί να το πιάσει το άλλο. Η ένωση τους δίνει πλουσιότερη περιγραφή κάθε εικόνας.

Αρχιτεκτονική



Preprocessing: Επειδή και τα δύο backbones μοιράζονται την ίδια είσοδο, χρησιμοποιούμε τον **μέσο όρο** των δύο preprocessing functions τους. Κρατά τις τιμές pixel σε εύρος που και τα δύο δίκτυα μπορούν να

χειριστούν.

Εκπαίδευση σε 2 Φάσεις

Φάση 1 — Και τα δύο backbones παγωμένα (10 epochs, lr=0.001): Μόνο το fusion head (BatchNorm + Dense + Dropout) εκπαιδεύεται. Ζεσταίνουμε πρώτα το κεφάλι.

Φάση 2 — Ξεπάγωμα τελευταίων 30 layers κάθε backbone (έως 30 epochs): Ξεπαγώνουμε τα τελευταία 30 layers **και των δύο** backbones ταυτόχρονα. Cosine decay από 3e-5. Έτσι και τα δύο δίκτυα προσαρμόζουν τα high-level χαρακτηριστικά τους στις ακτινογραφίες.

Αποτελέσματα

Μέτρο	Τιμή
Val Accuracy	78.67%
Val Loss	0.5345

Σύγκριση Όλων των Μοντέλων

Μοντέλο	Val Accuracy	Val Loss
Custom CNN (from scratch)	74.04%	0.5384
EfficientNetB0	73.98%	0.6138
DenseNet121 (Mike)	80.42%	0.4829
Dual-Backbone Fusion	78.67%	0.5345

Βασικά Συμπεράσματα για την Παρουσίαση

- Η μεταφορά γνώσης κερδίζει:** Τα μοντέλα που ξεκινούν από ImageNet weights συγκλίνουν γρηγορότερα και καλύτερα από το μοντέλο που εκπαιδεύτηκε από μηδέν.
- Partial unfreeze > Full unfreeze:** Το να ξεπαγώνεις μόνο τα τελευταία layers είναι πιο ασφαλές — διατηρείς τα ImageNet χαρακτηριστικά που είναι χρήσιμα και για ακτινογραφίες.
- Cosine Decay > ReduceLROnPlateau:** Πιο ομαλή μείωση του learning rate, λιγότερες αποτομές πτώσεις που μπορούν να αποσταθεροποιήσουν την εκπαίδευση.
- Δύο backbones > Ένα:** Η ένωση των χαρακτηριστικών δύο διαφορετικών αρχιτεκτονικών δίνει πλουσιότερη αναπαράσταση και καλύτερη ακρίβεια (+4.69% έναντι του μεμονωμένου EfficientNetB0).
- Class imbalance:** Το dataset έχει 60% normal / 40% abnormal. Χρησιμοποιήσαμε class weights {normal: 1.0, abnormal: 2.0} — το μοντέλο "τιμωρείται" διπλά όταν χάνει μια παθολογική εικόνα.
- Mixed precision:** Ενεργοποιήσαμε `mixed_float16` για τα δεδομένα (2x ταχύτερο, μισή μνήμη), αλλά το απενεργοποιήσαμε πριν την fine-tuning (το float16 μπορεί να αποσταθεροποιήσει τα gradients

κατά τη λεπτομερή εκπαίδευση).